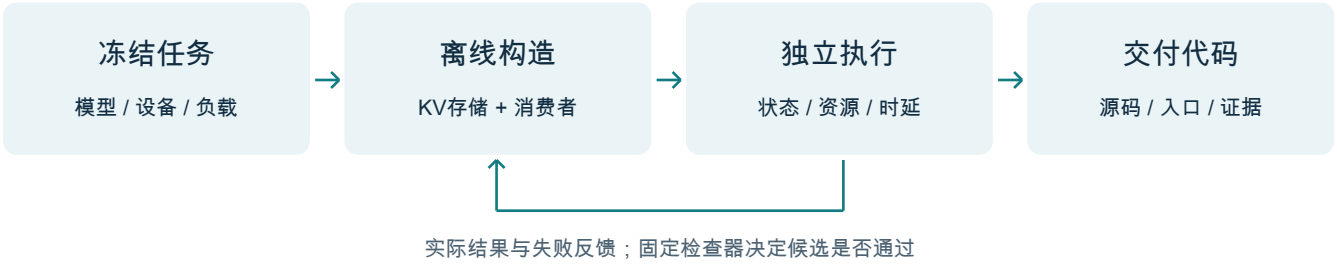
# InferenceForge

## 为具体模型、硬件与负载，生成配套的推理与存储代码

面向 AI 基础设施与研究团队，将 Coding Agent 的代码构造、真实 GPU 执行和固定验收连接起来。生成的运行时独立执行，Agent 不进入在线推理路径。




### 从一个可核查的 8B 场景开始

当前原型围绕 Qwen3-8B、单 A40、BF16，生成主机 KV 保存/恢复组件和配套会话消费者。先冻结模型数学与状态语义，再用真实失败和时延反馈迭代代码。它适合探索特定设备与负载的优化空间。

| 本次交付 | 已经有的直接依据 |
| --- | --- |
| 专用引擎与存储代码 | 公开 8B 实验入口、主机状态组件与会话消费者 |
| 可检查的正确性 | 九组真实 8B 主机状态检查；逐输出完整 logits、token 与 logprob 比对 |
| 有限、可复查的性能结果 | 组件恢复快 2.78-3.87 倍；恢复并生成 16 token 总时间只降低 0.4%-4.6% |
| 开源复现入口 | MIT 仓库、公开结果、25 项 CPU 回归记录及独立公开副本 GPU 复验 |

当前定位：可运行的研究原型。多会话联合改善约 0.815%，仍为 INCONCLUSIVE；未证明优于成熟推理或缓存系统。

中国科学技术大学 · 闫超美 · yanchaomei@mail.ustc.edu.cn

公开仓库：github.com/yanchaomei/inference-forge
冻结公开版本：0c555c1535d66f79dae908fa40078f1c3fc6b95e

# 01 机制：让存储与消费者共同适配

推理的批处理与逐层执行顺序决定 KV 何时被使用；KV 的物理组织与恢复路径决定复制、重排和显存占用。只让一个组件更快，未必能降低完整请求时延。InferenceForge 将这两部分放入同一次候选构造，用完整请求反馈检验组合。

## 固定什么，允许生成什么

| 层次 | 约束与职责 |
| --- | --- |
| 固定任务与参考 | 冻结模型权重、数学实现、精度、负载、资源预算和检查器；候选不能改写验收标准 |
| 生成存储组件 | 保存各层 KV 与下一步 FP32 logits；可改变主机布局、复制与同步方式 |
| 生成会话消费者 | 与存储配套；管理驻留、驱逐、恢复和增量追加；保留最后一个尚未进入 KV 的输出 token |
| 外部执行与反馈 | 逐输出检查完整 logits 摘要、token、logprob；记录时延、资源及失败，绑定实际源码 |

## 实际数据流与第二轮变化

会话 prefill → 保存主机状态 → 释放该会话 GPU KV → 需要时恢复 → 继续生成。主机恢复第二版使用锁页内存、集中 D2H 同步和同 stream 的 H2D 消费；会话第二版在首次驱逐保存全量快照，后续驱逐只写新增后缀。

可选增量接口依赖冻结消费者不修改已提交前缀。版本句柄校验身份和位置，不能证明任意张量内容不可变。通用 put/get/delete 保持无损和任意值语义；同 stream 有顺序保证，跨 stream 依赖由调用方建立。

## 反馈必须保留失败

会话候选第一轮出现四项接口失败，第二轮修复后复验通过。第二轮首次构造调用仅返回方案、未改码，耗时 145.81 秒；续接耗时 213.81 秒，整轮 359.63 秒。无代码变化的调用不计为成功候选。

主要方法参考：BespokeOLAP 的存储与执行共同生成、正确基线优先及真实执行反馈；这里是向推理状态场景迁移的原型，不声称复现该数据库系统或发明锁页内存等已有技术。

实现与语义：experiments/qwen3_8b/README.md

构造身份：experiments/qwen3_8b/provenance.json

# 02 主机恢复：局部加速与完整收益

两轮真实构造保持 8B 推理消费者不变：第一版生成同步主机拷贝实现，第二版接收实测反馈后优化传输与同步。两次构造分别耗时 58.71 秒、80.81 秒；这是一条两步构造链。

配置：Qwen3-8B / BF16 / TP1 / 单 A40。合成重复文本、固定前缀、权重驻留；每个长度 3 组 ABBA，每种恢复/重算路径各 6 次，报告中位数。两个候选顺序运行，未做候选交错重复。

| 输入 token | 初版恢复 ms | 二版恢复 ms | 恢复速度比 | 恢复+16 token 时间降低 |
|---|---|---|---|---|
| 128 | 4.184 | 1.082 | 3.87 倍 | 0.41% |
| 512 | 12.346 | 3.342 | 3.69 倍 | 1.56% |
| 1024 | 20.485 | 6.359 | 3.22 倍 | 2.36% |
| 2048 | 35.947 | 12.393 | 2.90 倍 | 3.59% |
| 3072 | 51.342 | 18.442 | 2.78 倍 | 4.59% |

## 正确性检查覆盖到实际恢复后的输出

每版通过九组真实模型状态检查，覆盖 B1 的五种 prefill 长度、两个 decode7 恢复点，以及 B2 的两种恢复时机。检查 KV 的 dtype、shape、逐字节内容和恢复后 16 步完整 logits 与 token 精确一致。

检查器另拒绝 put/get 私藏 CUDA 副本的两个控制负例，并检查 GPU 释放、非默认 stream、CPU 读写隔离、身份与容量拒绝、失败替换保留旧值。负例为人为注入，不描述为自然故障发现。

## 数据指向的下一步

主机恢复快 2.78-3.87 倍，但恢复并生成 16 token 总时间仅降低 0.4%-4.6%。这说明本开发点的完整时延仍受推理路径约束，不能用恢复速度代表整个框架的加速。

本结果证明相对冻结引擎的状态保持。单请求全命中与合成前缀不代表自然会话、生产 SLO 或独立模型质量；主机容量是已提交载荷限制，不是进程 RAM 峰值。

数据：results/qwen3-8b-host-state-20261031.json

独立公开副本验证：results/qwen3-8b-export-validation-20261031.json

# 03 六会话：配对代码可运行，优势待证

固定六个合成会话、24 轮、每轮生成 4 token；前缀为 512/1024/2048/3072 token。完成每轮时 GPU 会话状态预算 768 MiB，另记录瞬时峰值；主机已提交载荷预算 4 GiB。每种组合完整预热，再进行三次交错重复；时延含观察开销。

| 组件组合 | 三次 24 轮总耗时 ms | 中位 ms |
| --- | --- | --- |
| S0-E0<br>原存储 + 原消费者 | 7176.84 / 7160.08 / 7159.83 | 7160.08 |
| S1-E0<br>新存储 + 原消费者 | 7359.65 / 7146.66 / 7166.64 | 7166.64 |
| S0-E1<br>原存储 + 新消费者 | 7140.67 / 7813.12 / 7287.06 | 7287.06 |
| S1-E1<br>新存储 + 新消费者 | 7097.75 / 7101.71 / 7103.92 | 7101.71 |

## 中位耗时降低 0.815%：INCONCLUSIVE

只有三次开发重复、单一合成轨迹和共享主机，当前不足以支持稳健的联合优势。四格是同一个联合候选的组件交叉消融，没有比较两个独立构造器分别优化后的组合。

## 432 条记录究竟代表什么

18 份运行记录包括：1 份无换出参考、4 份预热、12 份计时、1 份全驻留对照，共 432 轮请求和 1,728 个输出位置。它们不是 432 次独立实验。各位置的 token、logprob 与完整 logits 摘要均匹配参考；各运行 close 后 GPU 和主机载荷归零。

参考采用同一冻结引擎的无换出路径。因此通过意味着存储与会话状态保持，不能扩展为独立模型质量验证。逻辑写回量减少也不能替代实际 PCIe 流量或完整请求收益。

仍缺：自然负载、独立留出、相同预算的多次真实构造、成熟缓存系统集成与统一质量门。VibeSys/MetaInfer 构造对照尚无有效候选，不称复现完成；不据本表宣称超过 vLLM、SGLang 或 Mooncake。

逐请求数据与统计：results/qwen3-8b-sessions-20261031.json

# 04 开源使用、复现与交付边界

公开仓库提供代码、安装说明、实验入口、数据和 MIT 许可证。8B 实验使用独立依赖与入口；首页 0.5B 快速开始不能替代 8B 环境。生成与代码编辑在本地，模型执行、检查与测量在 Linux GPU 服务器完成。

| 使用顺序 | 入口与应观察的结果 |
| --- | --- |
| 1. 固定版本与模型 | checkout 本报告公开提交；准备 Qwen3-8B 指定 revision，核验官方文件身份；不分发权重 |
| 2. 验证现有产物 | check_candidate / check_retained_protocol；host_roundtrip --correctness-only：检查接口及九组状态保持 |
| 3. 运行四格开发评测 | session_matrix --repeats 3：保存每种组合预热、逐输出检查、时延和资源释放记录 |
| 4. 构造新候选 | construct：保留调用、用量及源码；generated_not_validated 仍需 GPU 验收 |

## 公开交付的验证状态

PR #1 已合并；冻结公开提交 0c555c1，主分支 CPU CI 41170000960 成功。公开 25 项 CPU 回归通过；独立公开副本完成九组真实 8B 主机状态与一次四格复验。该单次复验验证公开入口可运行，不替代研究的三次重复。

## 历史视频与本次材料的关系

包内复用 90 秒字幕视频：2026-10-30 的 Qwen2.5-0.5B 实际运行记录回放，等待已压缩，非 8B 实时演示，无配音。旧 2.34 倍结果只相对其自身初版，不能与本报告 8B 数值拼成性能排名。

## 适用范围与后续工作

目前 8B 实验没有 HTTP 会话服务、NVMe、多线程控制、取消和自动故障恢复。自然负载、独立模型质量、成熟系统强对照与论文定稿仍待完成；本报告不引用尚未验收的新性能试验。

申报信息已知：单位、姓名与邮箱如首页。主体类型、联系电话待补；官方截止、门户字段与附件限制待核实。本次完成材料准备，不代表报名、上传、正式提交或主办方接受。

完整复现命令与语义：experiments/qwen3_8b/README.md

包内另附：使用指南、主张到证据映射、公开结果快照、页面视觉检查记录和文件完整性清单。